

Ανίχνευση παικτών και μπάλας στο SoccerNet_v3_H250 με YOLOv8

Δημήτριος Κωστήρης
Πανεπιστήμιο Πειραιώς
Τμ. Ψηφιακών Συστημάτων
Πειραιάς, Ελλάδα
dimkostir@gmail.com

Αντώνιος Παπακωνσταντίνου
Πανεπιστήμιο Πειραιώς
Τμ. Ψηφιακών Συστημάτων
Πειραιάς, Ελλάδα
antonispap@icloud.com

Περίληψη—Στην παρούσα εργασία, στο πλαίσιο του μαθήματος Βαθιά Μάθηση και Τεχνητή Νοημοσύνη, υλοποιείται ένα σύστημα μηχανικής μάθησης το οποίο πραγματοποιεί ανίχνευση παικτών και μπάλας, σε εικόνες από το σύνολο δεδομένων SoccerNet_v3_H250, με τη χρήση μοντέλων YOLOv8. Αξιολογούνται 3 μοντέλα-nano, small, medium- ενώ γίνεται επίσης πείραμα με υποσύνολο (50%) του αρχικού συνόλου δεδομένων. Μετά τα πειράματα, συμπεραίνεται πως τα μοντέλα αυτά αποδίδουν εξαιρετικά πάνω σε τέτοια σύνολα δεδομένων, παρατηρώντας ωστόσο δυσκολία στην ανίχνευση της μπάλας, σε σύγκριση με την ανίχνευση των παικτών.

Λέξεις κλειδιά—YOLOv8, Soccernet_v3_H250, ανίχνευση παικτών, computer vision

I. ΕΙΣΑΓΩΓΗ

Στη σύγχρονη εποχή, η ραγδαία εξέλιξη της τεχνολογίας, έχει αναμφίβολα επηρεάσει και τομείς όπως αυτό του αθλητισμού και πιο συγκεκριμένα του ποδοσφαίρου. Η ανάγκη περαιτέρω ανάλυσης του αθλήματος, έχει φέρει στο προσκήνιο χρήση τεχνικών όπως η ανάλυση βίντεο, με χρήση τεχνητής νοημοσύνης. Υπάρχει μεγάλη ανάπτυξη εφαρμογών, τόσο ανάλυσης απόδοσης όσο και ανάλυσης τακτικών, οι οποίες χρησιμοποιούν είτε υλικό από βιντεοσκοπήσεις των μεταδόσεων των αγώνων, είτε από υλικό των ομάδων και με χρήση μοντέλων βαθιάς μάθησης πραγματοποιούν οπτική ανάλυση [1].

Υπάρχουν εργασίες, οι οποίες επιχειρούν να εμβαθύνουν στο παραπάνω πρόβλημα, όπως αυτή των Μουτσέλου-Μαγκλογιάννη, “Setting a Baseline for long-shot real-time Player and Ball detection in Soccer Videos” [2], ή όπως αυτή των Komorowski-Kurzejanski-Sarwas, “FootAndBall: Integrated player and ball detector” [3]. Η πρώτη αναφερθείσα, επισημαίνει ότι, μέχρι πρόσφατα, η αντικειμενική σύγκριση μοντέλων εντοπισμού στον χώρο του ποδοσφαίρου ήταν πρακτικά αδύνατη. Προηγούμενα ανοιχτά σύνολα δεδομένων, όπως το ISSIA-CNR και το Soccer Player Detection, παρουσίαζαν σοβαρές ελλείψεις και ανακρίβειες. Για παράδειγμα, παρατηρήθηκαν λανθασμένα πλαίσια οριοθέτησης παικτών, απουσία εντοπισμού της μπάλας ή και διακοπή καταγραφής ενός παίκτη όταν αυτός βρισκόταν στο έδαφος. Για τον λόγο αυτό δημιουργήθηκε το σύνολο δεδομένων SoccerNet_v3_H250 [4], το οποίο αποτελεί υποσύνολο του συνόλου δεδομένων SoccerNet [5] και επικεντρώνεται σε “μακρινά πλάνα”, κρατώντας μόνο τα καρέ όπου το μέγιστο

ύψος (μήκος του bounding box) ενός παίκτη δεν υπερβαίνει τα 250 pixel. Γίνεται σύγκριση μεθόδων YOLOv8, το οποίο παρουσιάζει εξαιρετικά αποτελέσματα, και ενός μοντέλου από την εργασία “FootAndBall”, για την εξαγωγή αποτελεσμάτων της ανάλυσης των ποδοσφαιρικών εικόνων.

Στο “FootAndBall”, υλοποιείται ένα ελαφρύ νευρωνικό δίκτυο, με αρχιτεκτονική FPN, περίπου 199.000 παραμέτρων. Τα προβλήματα τα οποία παρουσίασε, αφορούν αρχικά το ελλιπές και γεμάτο λάθη σύνολο δεδομένων, καθώς και την χαμηλή του απόδοση, ιδιαίτερα σε σχέση με το μοντέλο YOLOv8.

Το σύνολο δεδομένων SoccerNet_v3_H250, καθίσταται ιδανικό καθώς είναι ένα επεξεργασμένο υποσύνολο, περιλαμβάνει κανονικοποιημένα annotations και συμπεριλαμβάνει μόνο δύο ομάδες κατηγοριοποίησης. Στην παρούσα εργασία, γίνεται ουσιαστικά επέκταση της εργασίας πάνω στο SoccerNet_v3_H250, ερευνώντας επιπλέον μεθόδους μηχανικής μάθησης για ταξινόμηση κλάσεων. Η λύση η οποία προτείνεται είναι αρχικά η δοκιμή πολλαπλών μοντέλων του YOLOv8, καθώς και η διερεύνηση επεξεργασίας σε σημαντικά μειωμένο σύνολο δεδομένων, της τάξης του 50%. Πιο συγκεκριμένα, πραγματοποιούνται πειράματα με τα μοντέλα nano, small, medium με το πλήρες σύνολο των δεδομένων SoccerNet_v3_H250, αλλά και με το μοντέλο small χρησιμοποιώντας το 50% των δεδομένων.

Όσον αφορά τη δομή της παρούσας εργασίας, μετά την εισαγωγή, ακολουθούν τα εξής κεφάλαια: Η μεθοδολογία, όπου περιγράφεται ο τρόπος υλοποίησης της εργασίας, το πως αξιοποιούνται τα μοντέλα μηχανικής μάθησης καθώς και η χρήση του συνόλου δεδομένων. Στη συνέχεια, ακολουθεί το κεφάλαιο των αποτελεσμάτων, στο οποίο αρχικά γίνεται η περιγραφή του συνόλου δεδομένων που χρησιμοποιήθηκε. Επιπλέον, αναφέρεται η πειραματική μεθοδολογία που ακολουθήθηκε, οι διάφορες παράμετροι των μοντέλων, καθώς και τα αποτελέσματα, συνοδευόμενα από διαγράμματα και εικόνες. Τέλος, ακολουθούν τα συμπεράσματα, όπου πραγματοποιείται σύντομη αναφορά στο τι μελετήθηκε, στα συμπεράσματα που προκύπτουν και στις μελλοντικές προοπτικές ανάπτυξης της έρευνας.

Στην παρούσα εργασία πραγματοποιούνται πειράματα με τα εξής μοντέλα:

- 1) YOLOv8 **nano** (3m parameters) στο πλήρες σύνολο δεδομένων
- 2) YOLOv8 **small** (11m parameters) στο πλήρες σύνολο δεδομένων
- 3) YOLOv8 **medium** (25m parameters) στο πλήρες σύνολο δεδομένων
- 4) YOLOv8 **small** (11m parameters) στο **50%** των δεδομένων

Οι παράμετροι εκπαίδευσης οι οποίοι χρησιμοποιήθηκαν είναι οι εξής:

- 1) **Epochs = 50** : ο αριθμός πλήρων περασμάτων από το training set. Επιλέχθηκε ως ισορροπία μεταξύ επαρκούς εκπαίδευσης και υπολογιστικού κόστους. Το early stopping αποτρέπει σπατάλη αν το μοντέλο συγκλίνει νωρίτερα.
- 2) **Imgsize = 640** : το μέγεθος στο οποίο αλλάζουν διαστάσεις (resize) οι εικόνες πριν την εκπαίδευση.
- 3) **Batch = 16** : πόσες εικόνες επεξεργάζεται ταυτόχρονα ανά βήμα.
- 4) **Patience = 10** : αν το mAP50 (metric αξιολόγησης) δεν βελτιωθεί για 10 συνεχόμενα epochs, το training σταματά αυτόματα (early stopping). Αποτρέπει overfitting και εξοικονομεί υπολογιστικό χρόνο.

B. Περιβάλλον εκτέλεσης

Τα πειράματα εκτελέστηκαν στο περιβάλλον Google Colaboratory, αξιοποιώντας επιταχυντή γραφικών NVIDIA A100 SXM4 (40GB VRAM). Το λογισμικό που χρησιμοποιήθηκε περιλαμβάνει Python 3.12, PyTorch 2.11 και τη βιβλιοθήκη Ultralytics YOLOv8 έκδοση 8.4, μέσω της οποίας πραγματοποιήθηκε τόσο η εκπαίδευση όσο και η αξιολόγηση των μοντέλων.

C. Περιγραφή του Dataset "SoccerNet_v3_H250"

Το σύνολο δεδομένων που χρησιμοποιείται στην παρούσα εργασία είναι το SoccerNet_v3_H250 [4], το οποίο αποτελεί επεξεργασμένο υποσύνολο του SoccerNet_v3 [5]. Το SoccerNet_v3 είναι μια εκτενής συλλογή 400 ποδοσφαιρικών αγώνων, διαιρεμένη σε αναλογία 290/55/55 για εκπαίδευση (training), επικύρωση (validation) και αξιολόγηση (testing), με λεπτομερή annotations που περιλαμβάνουν, μεταξύ άλλων, πλαίσια οριοθέτησης για παίκτες και μπάλα.

Στο πλαίσιο της εργασίας των Μουτσέλου-Μαγκλογιάννη [2], επισημάνθηκε ότι τα υπάρχοντα σύνολα δεδομένων που σχετίζονται με τον αθλητισμό και συγκεκριμένα με τον χώρο του ποδοσφαίρου, παρουσίαζαν σοβαρές ελλείψεις, καθιστώντας την αντικειμενική σύγκριση μοντέλων πρακτικά αδύνατη. Σύνολα όπως το ISSIA-CNR και το Soccer Player Detection περιείχαν ανακριβείς στα ground-truth annotations, απουσία εντοπισμού της μπάλας ή διακοπή καταγραφής παικτών σε συγκεκριμένες συνθήκες. Για τον λόγο αυτό, δημιουργήθηκε το SoccerNet_v3_H250, το οποίο εφαρμόζει φιλτράρισμα βάσει του μέγιστου ύψους του bounding box ενός παίκτη ανά καρέ, κρατώντας αποκλειστικά τα καρέ στα οποία το ύψος αυτό δεν υπερβαίνει τα 250 pixels. Με τον τρόπο αυτό,

το dataset επικεντρώνεται σε μακρινά πλάνα, τα οποία αποτελούν και την πιο απαιτητική περίπτωση για αλγόριθμους ανίχνευσης, καθώς τα αντικείμενα εμφανίζονται σε μικρό μέγεθος και με μειωμένη ευκρίνεια.

Το σύνολο δεδομένων αποτελείται συνολικά από 19.786 εικόνες, διαιρεμένες σε τρία υποσύνολα: 14.368 εικόνες εκπαίδευσης, 2.726 εικόνες επικύρωσης και 2.692 εικόνες αξιολόγησης. Τα annotations βρίσκονται σε μορφή συμβατή με τον αλγόριθμο YOLO και περιλαμβάνουν δύο μόνο κλάσεις: 0 για την μπάλα και 1 για τον παίκτη. Πιο συγκεκριμένα, ως "παίκτης" ορίζεται κάθε άνθρωπος στο γήπεδο, συμπεριλαμβανομένων διαιτητών και προπονητών, συγχωνεύοντας έτσι τις 7 αρχικές κατηγορίες ανθρώπων του SoccerNet v3 σε μία ενιαία. Η απλοποίηση αυτή, καθίσταται σκόπιμη και ιδιαίτερα ευεργετική, καθώς σκοπός ενός πρώτου σταδίου ανάλυσης ποδοσφαιρικού βίντεο είναι ο εντοπισμός όλων των προσώπων στο γήπεδο, με τη λεπτομερέστερη κατηγοριοποίηση σε παίκτες, διαιτητές ή φιλάθλους να αποτελεί ένα μεταγενέστερο βήμα.

D. Αποτελέσματα

Στην ενότητα αυτή παρουσιάζονται και αναλύονται τα αποτελέσματα των τεσσάρων πειραμάτων που πραγματοποιήθηκαν στο σύνολο δεδομένων SoccerNet_v3_H250. Η αξιολόγηση των μοντέλων πραγματοποιείται στο test set, εξασφαλίζοντας έτσι την αντικειμενικότητα και ποιότητα των αποτελεσμάτων. Επιπρόσθετα, για κάθε μοντέλο αναφέρονται οι μετρικές Precision, Recall, mAP50 και mAP50-95, τόσο συνολικά όσο και ανά κλάση (ball, person), ώστε να αναδειχθούν οι διαφορές στην απόδοση μεταξύ των δύο κατηγοριών. Επιπλέον, πραγματοποιείται σύγκριση με τα αποτελέσματα της εργασίας των Μουτσέλου-Μαγκλογιάννη [2], η οποία αποτελεί ένα βασικό σημείο αναφοράς της παρούσας μελέτης.

Στον πίνακα I, αναλύονται τα αποτελέσματα των πειραμάτων, ανά κλάση, "person"- "ball", καταδεικνύοντας μια σημαντική ανισορροπία στην απόδοση κατηγοριοποίησης τους. Η ανίχνευση παικτών (person) επιτυγχάνει εξαιρετικές επιδόσεις σε όλα τα μοντέλα, με mAP50 που κυμαίνεται μεταξύ 0.967 και 0.975, αποδεικνύοντας ότι ακόμα και το μικρότερο μοντέλο (nano) είναι εξαιρετικά αποτελεσματικό για τον εντοπισμό των παικτών. Αντίθετα, η ανίχνευση μπάλας παραμένει μια δυσκολότερη πρόκληση, με mAP50 να κυμαίνεται από 0.469 (nano) έως 0.593 (medium), τιμές οι οποίες είναι αισθητά χαμηλότερες. Η δυσκολία αυτή αποδίδεται στο μικρό μέγεθος της μπάλας, σε σχέση με τους παίκτες, στις εικόνες μακρινών πλάνων, στην υψηλή ταχύτητα κίνησής της που προκαλεί κάποιο "θόλωμα", καθώς και στην έντονη ανισορροπία κλάσεων, με 38.004 οντότητες παικτών έναντι μόλις 2.108 μπάλας στο test set. Αξιοσημείωτο είναι επίσης ότι η μείωση του training set στο 50%, επηρεάζει σχεδόν αποκλειστικά την ανίχνευση μπάλας (mAP50: από 0.554 σε 0.506), αφήνοντας την ανίχνευση παικτών ουσιαστικά αναλλοίωτη (από 0.968 σε 0.967), γεγονός που επιβεβαιώνει ότι η μπάλα απαιτεί εμφανώς περισσότερα δεδομένα εκπαίδευσης για πιο αξιόπιστη και αποτελεσματική ανίχνευση.

ΠΙΝΑΚΑΣ Ι. ΑΠΟΤΕΛΕΣΜΑΤΑ ΑΞΙΟΛΟΓΗΣΗΣ ΣΤΟ TEST SET ΑΝΑ ΚΛΑΣΗ


Μοντέλο	Κλάση	P	R	mAP50	mAP50-95
YOLOv8n (100%)	ball	0.716	0.456	0.469	0.183
	person	0.958	0.947	0.967	0.711
YOLOv8s (100%)	ball	0.727	0.552	0.554	0.224
	person	0.960	0.952	0.968	0.722
YOLOv8m (100%)	ball	0.752	0.602	0.593	0.245
	person	0.965	0.955	0.975	0.729
YOLOv8s (50%)	ball	0.720	0.502	0.506	0.200
	person	0.959	0.946	0.967	0.716

Στον Πίνακα ΙΙ, παρουσιάζονται τα συνολικά αποτελέσματα αξιολόγησης στο test set για τα τέσσερα πειράματα. Παρατηρείται σαφής και σταθερή βελτίωση με την αύξηση του μεγέθους του μοντέλου: Πιο συγκεκριμένα, το YOLOv8n επιτυγχάνει mAP50=0.718, το YOLOv8s ανεβάζει την τιμή στο 0.761 (+0.043), ενώ το YOLOv8m πετυχαίνει την υψηλότερη απόδοση με mAP50=0.784 (+0.023). Παράλληλα, η μείωση του training set στο 50% επηρεάζει αρνητικά την απόδοση του YOLOv8s, με το mAP50 να πέφτει από 0.761 σε 0.736, αποδεικνύοντας ότι το μέγεθος του συνόλου εκπαίδευσης διαδραματίζει σημαντικό ρόλο. Αξιοσημείωτο είναι επίσης ότι το YOLOv8m συγκλίνει νωρίτερα (epoch 44) σε σχέση με το YOLOv8n (epoch 49), γεγονός που υποδηλώνει ότι τα μεγαλύτερα μοντέλα "μαθαίνουν" αποδοτικότερα τα χαρακτηριστικά του dataset.


ΠΙΝΑΚΑΣ ΙΙ. ΣΥΝΟΛΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ ΑΞΙΟΛΟΓΗΣΗΣ ΣΤΟ TEST SET

Μοντέλο	P	R	mAP50	mAP50-95
YOLOv8n (100%)	0.836	0.702	0.718	0.447
YOLOv8s (100%)	0.843	0.752	0.761	0.473
YOLOv8m (100%)	0.859	0.779	0.784	0.487
YOLOv8s (50%)	0.839	0.724	0.736	0.458


Στις εικόνες 2-5 που ακολουθούν, παρουσιάζονται οι καμπύλες εκπαίδευσης και αξιολόγησης για τα 4 πειράματα που διενεργήθηκαν. Σε όλα τα μοντέλα, παρουσιάζεται ομαλή και μονότονη μείωση της συνάρτησης απώλειας (loss function), τόσο στο training όσο και στο validation set. Επιπλέον, δεν υπάρχουν σημάδια overfitting, γεγονός το οποίο επιβεβαιώνει την ορθή επιλογή παραμέτρων. Επίσης, σε όλα τα μοντέλα, παρατηρείται αστάθεια στα πρώτα epochs, στο κομμάτι που αφορά το precision. Το φαινόμενο αυτό θα μπορούσε να αποδοθεί στο πρώιμο στάδιο της εκπαίδευσης. Επιπρόσθετα, μέσω των γραφημάτων επιβεβαιώνονται και οι μετρικές από τους παραπάνω πίνακες, όπως για παράδειγμα το υψηλότερο mAP50 του YOLOv8m. Μια ακόμα σημαντική παρατήρηση η οποία θα μπορούσε να γίνει, είναι πως η καμπύλη mAP50 του YOLOv8s στο 100% των δεδομένων, σταθεροποιείται αρκετά νωρίτερα από την αντίστοιχη του YOLOv8s στο 50% των δεδομένων. Σαν συμπέρασμα θα μπορούσε να συνταχθεί πως η μειωμένη ποσότητα δεδομένων, επιβραδύνει τη σύγκλιση του μοντέλου.




Εικόνα 2: Αποτελέσματα YOLOv8 nano



Εικόνα 3: Αποτελέσματα YOLOv8 small 100% δεδομένα



Εικόνα 4: Αποτελέσματα YOLOv8 small 50% δεδομένα



Εικόνα 5: Αποτελέσματα YOLOv8 medium

Στον Πίνακα III παρουσιάζονται οι συνολικοί χρόνοι εκπαίδευσης για τα τέσσερα πειράματα. Όλα τα πειράματα εκτελέστηκαν σε GPU NVIDIA A100 SXM4 (40GB VRAM), ο οποίος επιτρέπει την εκπαίδευση μεγάλων μοντέλων σε εύλογο χρόνο. Παρατηρείται αύξηση του χρόνου εκπαίδευσης με την αύξηση του μεγέθους του μοντέλου, από 1.602 ώρες για το μοντέλο nano έως 2.064 ώρες για το μοντέλο medium, γεγονός που αντικατοπτρίζει την αύξηση των παραμέτρων και των υπολογισμών ανά epoch. Αξιοσημείωτο είναι ότι το Πείραμα 4 (YOLOv8s, 50% δεδομένων) ολοκληρώθηκε σε μόλις 0.764 ώρες, δηλαδή σχεδόν στο μισό χρόνο του αντίστοιχου Πειράματος 2 (1.645 ώρες), καθώς το μειωμένο training set μειώνει αναλογικά τον αριθμό των batches ανά epoch.

ΠΙΝΑΚΑΣ III. ΧΡΟΝΟΙ ΕΚΠΑΙΔΕΥΣΗΣ ΑΝΑ ΠΕΙΡΑΜΑ

Πείραμα	Μοντέλο	Δεδομένα	Χρόνος Εκπαίδευσης
1	YOLOv8n	100%	1.602 h
2	YOLOv8s	100%	1.645 h
3	YOLOv8m	100%	2.064 h
4	YOLOv8s	50%	0.764 h

E. Σύγκριση αποτελεσμάτων

Για τη σύγκριση των αποτελεσμάτων της παρούσας εργασίας, με αυτή των Μουτσέλου-Μαγκλογιάννη [2], θα πρέπει να γίνουν κάποιες παραδοχές. Αυτές αφορούν το γεγονός ότι οι μετρικές αποτελεσμάτων τους είναι διαφορετικές, με αποτέλεσμα η σύγκριση να μην είναι εφικτή με το απόλυτο της ακρίβειας. Πιο συγκεκριμένα, στην εργασία Μουτσέλου-Μαγκλογιάννη, αποτελέσματα ερμηνεύονται χρησιμοποιώντας τις μετρικές AP11 και COCO mAP. Όπως προαναφέρθηκε, στην παρούσα εργασία οι μετρικές είναι οι mAP50 και mAP50-95, της Ultralytics. Η πλησιέστερη δυνατή σύγκριση η οποία θα μπορούσε να πραγματοποιηθεί αφορά τις COCO mAP και mAP50-95, καθώς και οι δύο μετρικές υπολογίζουν μέσο όρο για εύρος IoU από 0.50 έως 0.95. Με βάση αυτή τη σύγκριση, το καλύτερο μοντέλο της παρούσας εργασίας (YOLOv8m) επιτυγχάνει $mAP50-95=0.729$ για την κλάση person και $mAP50-95=0.245$ για την κλάση ball, έναντι COCO $mAP=0.682$ και 0.121 αντίστοιχα για το Ytr640 των Μουτσέλου-Μαγκλογιάννη. Τα αποτελέσματα αυτά είναι θετικά, ωστόσο η άμεση σύγκριση παραμένει αβέβαιη λόγω διαφορών στις παραμέτρους εκπαίδευσης. Συμπερασματικά, τα αποτελέσματα και των δύο εργασιών επιβεβαιώνουν την υπεροχή του YOLOv8 έναντι παλαιότερων αρχιτεκτονικών, καθώς και τη σημαντική πρόκληση που εξακολουθεί να αποτελεί η ανίχνευση της μπάλας σε τέτοιου είδους πλάνα.

IV. ΣΥΜΠΕΡΑΣΜΑΤΑ

A. Συμπεράσματα που προκύπτουν

Στην παρούσα εργασία πραγματοποιήθηκε συγκριτική μελέτη τριών παραλλαγών του μοντέλου YOLOv8, nano, small και medium, για την ανίχνευση παικτών και μπάλας σε εικόνες ποδοσφαίρου μακρινών πλάνων, χρησιμοποιώντας το σύνολο δεδομένων SoccerNet_v3_H250 [4]. Παράλληλα, διερευνήθηκε η επίδραση του μεγέθους του συνόλου εκπαίδευσης μέσω σύγκρισης πλήρους (100%) και μειωμένου (50%) dataset, κάνοντας χρήση του μοντέλου YOLOv8s. Τα αποτελέσματα αναλύθηκαν ανά κλάση και συνολικά, με βάση τις μετρικές Precision, Recall, mAP50 και mAP50-95 στο test set, ενώ πραγματοποιήθηκε και σύγκριση με τα αποτελέσματα της εργασίας των Μουτσέλου-Μαγκλογιάννη, η οποία αποτέλεσε το κύριο σημείο αναφοράς της παρούσας μελέτης.

Προκύπτουν ορισμένα συμπεράσματα από την παραπάνω έρευνα. Αρχικά, επιβεβαιώνεται το γεγονός πως η ανίχνευση παικτών ή γενικότερα ατόμων στον αγωνιστικό χώρο, είναι μια σαφώς πιο εύκολη και ακριβής διαδικασία σε σχέση με την ανίχνευση της μπάλας. Επιπρόσθετα, το μέγεθος του dataset στα πειράματα, επηρεάζει κυρίως την ανίχνευση της μπάλας, παρά των παικτών. Το μοντέλο το οποίο προτείνεται, με βάση την παρούσα εργασία είναι το YOLOv8 medium, ωστόσο αναμφίβολα θα μπορούσαν να χρησιμοποιηθούν μεγαλύτερα μοντέλα, με ακόμα καλύτερα προσδοκώμενα αποτελέσματα.

V. ΜΕΛΛΟΝΤΙΚΕΣ ΠΡΟΟΠΤΙΚΕΣ

Κάποιες μελλοντικές προοπτικές εξέλιξης της παρούσας εργασίας, αφορούν, όπως προαναφέρθηκε, τη χρήση μεγαλύτερων μοντέλων του YOLOv8, όπως τα large και extra large, τα οποία ωστόσο απαιτούν πολύ μεγαλύτερες υπολογιστικές υποδομές και χρόνο. Επιπρόσθετα, θα

μπορούσαν να γίνουν δοκιμές με διαφορετικές παραμέτρους εκπαίδευσης, όπως περισσότερα epochs, μεγαλύτερο imgsiz, ενδεικτικά 1280, όπως στην εργασία των Μουτσέλου-Μαγκλογιάννη [2], όπου και παρατηρήθηκε σημαντική βελτίωση στην ανίχνευση της μπάλας, ή ακόμα και κάποιοι διαφορετικοί optimizers. Επιπλέον, η χρήση νεότερων μοντέλων, όπως το YOLOv12 [8], το οποίο εισάγει μηχανισμούς attention για βελτιωμένη εξαγωγή χαρακτηριστικών, ή το YOLO26 [9], που υλοποιεί native end-to-end inference χωρίς NMS, καθίσταται ιδιαίτερα ενδιαφέρουσα για τη σύγκριση των αποτελεσμάτων στο ίδιο dataset. Μία ακόμα κατεύθυνση αφορά την εφαρμογή εξειδικευμένων τεχνικών data augmentation, με κύριο στόχο τη βελτίωση της ανίχνευσης της μπάλας, όπως για παράδειγμα, τεχνητή αύξηση των instances μπάλας για την αντιμετώπιση της έντονης ανισορροπίας κλάσεων, κάτι το οποίο θα μπορούσε να συνεισφέρει σημαντικά σε πληθώρα ποδοσφαιρικών εφαρμογών. Τέλος, η αξιολόγηση των μοντέλων σε πραγματικές συνθήκες, μέσω real-time εφαρμογής σε βίντεο αγώνων, θα αποτελούσε το επόμενο φυσικό βήμα, καθώς η απόδοση σε πραγματικό χρόνο είναι αυτή που καθορίζει την πρακτική αξία τέτοιων συστημάτων.

ΒΙΒΛΙΟΓΡΑΦΙΑ

- [1] P. Mavrogiannis and I. Maglogiannis, "Amateur football analytics using computer vision," *Neural Computing and Applications*, Aug. 2022, doi: 10.1007/s00521-022-07692-6.
- [2] K. Moutselos and I. Maglogiannis, "Setting a Baseline for long-shot real-time Player and Ball detection in Soccer Videos," in *Proc. 14th International Conference on Information, Intelligence, Systems & Applications (IISA)*, 2023, doi: 10.1109/IISA59645.2023.10345947.
- [3] J. Komorowski, G. Kurzejamski, and G. Sarwas, "FootAndBall: Integrated Player and Ball Detector," in *Proc. 15th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications*, 2020, pp. 47–56, doi: 10.5220/0008916000470056.
- [4] K. Moutselos, "SoccerNet_v3_H250 Dataset," Zenodo, 2023. [Online]. Available: <https://zenodo.org/record/7808511>. [Accessed: Ιούν. 2026].
- [5] "SoccerNet-v3." SoccerNet, Mar. 14, 2023. Accessed: Mar. 18, 2023. [Online]. Available: <https://github.com/SoccerNet/SoccerNet-v3>
- [6] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, doi: 10.1109/CVPR.2016.91.
- [7] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," Ultralytics, 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>. [Accessed: Ιούν. 2026].
- [8] Y. Tian, Q. Ye, and D. Doermann, "YOLOv12: Attention-Centric Real-Time Object Detectors," *arXiv preprint arXiv:2502.12524*, Feb. 2025. [Online]. Available: <https://arxiv.org/abs/2502.12524>.
- [9] G. Jocher et al., "Ultralytics YOLO26," *arXiv preprint arXiv:2606.03748*, 2026. [Online]. Available: <https://docs.ultralytics.com/models/yolo26>. [Accessed: Ιούν. 2026].